

1 Plan ćwiczenia.

a) Przeprowadzić modelowanie z użyciem sztucznej sieci neuronowej następującej funkcji:

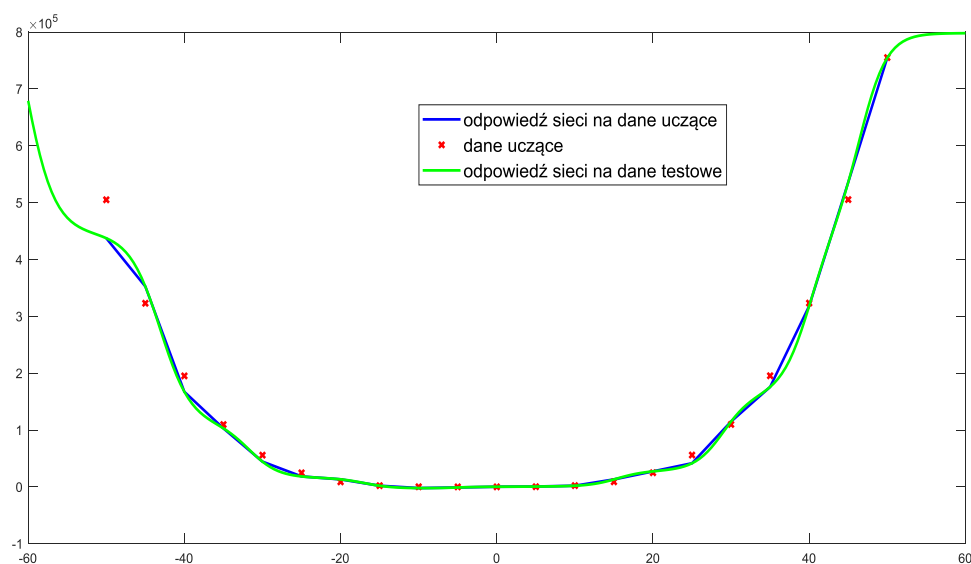
$$f_1(x) = 0.1x^4 + x^3 + 2x^2 + x + 5$$

modelowanie przeprowadzić zarówno dla idealnych jak i zaszumionych danych.


b) Dla obiektu danego w treści ćwiczenia przeprowadzić modelowanie sztuczną siecią neuronową, obserwując wyniki przy różnej liczbie neuronów, różnych algorytmach uczenia sieci oraz nieznacznie zaszumionych danych.

2 Modelowanie funkcji.

W pierwszej kolejności zamodelowano funkcję w postaci sieci neuronowej złożonej z 10 neuronów, dla idealnych danych. Na rysunkach 1 i 2 przedstawiono otrzymane wyniki:




Rysunek 1 – Wyniki modelowania relacji statycznej dla liczby neuronów równej 10.




Rysunek 2 – Błąd modelowania relacji statycznej dla liczby neuronów równej 10.

Można na powyższych rysunkach zaobserwować znaczne różnice między odpowiedzią sieci, a danymi uczącymi. Szczególnie po prawej stronie wykresu, gdzie uzyskana odpowiedź znacząco zmienia charakter poza zakresem danych uczących. Wskazuje to na zbyt złożoną strukturę sieci, dlatego zmniejszono ilość neuronów do 6. Wyniki są na rys. 3 i 4.




Rysunek 3 – Wyniki modelowania relacji statycznej dla liczby neuronów równej 6.

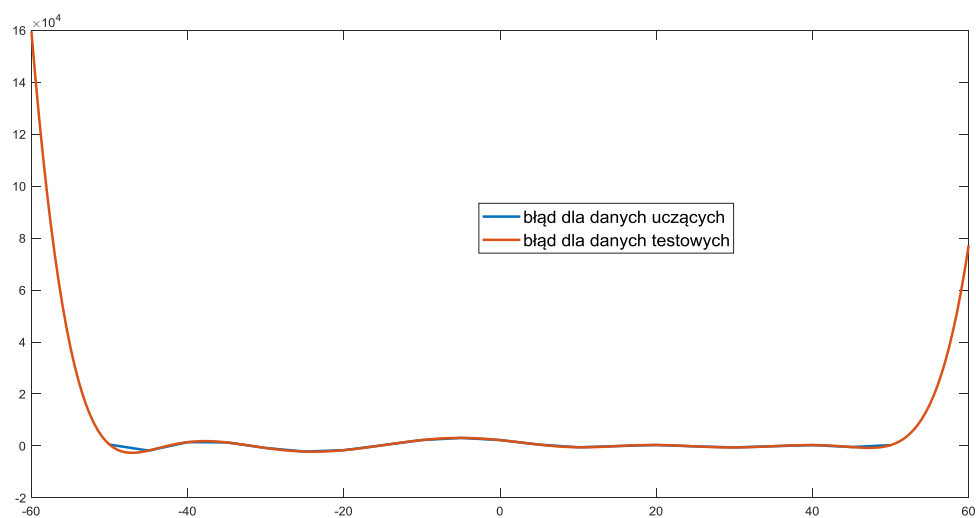


Rysunek 4 – Błąd modelowania relacji statycznej dla liczby neuronów równej 6.

Można zauważyć poprawę dokładności odwzorowania, jednak ciągle błędy są widoczne. Zmniejszono liczbę neuronów do 3.

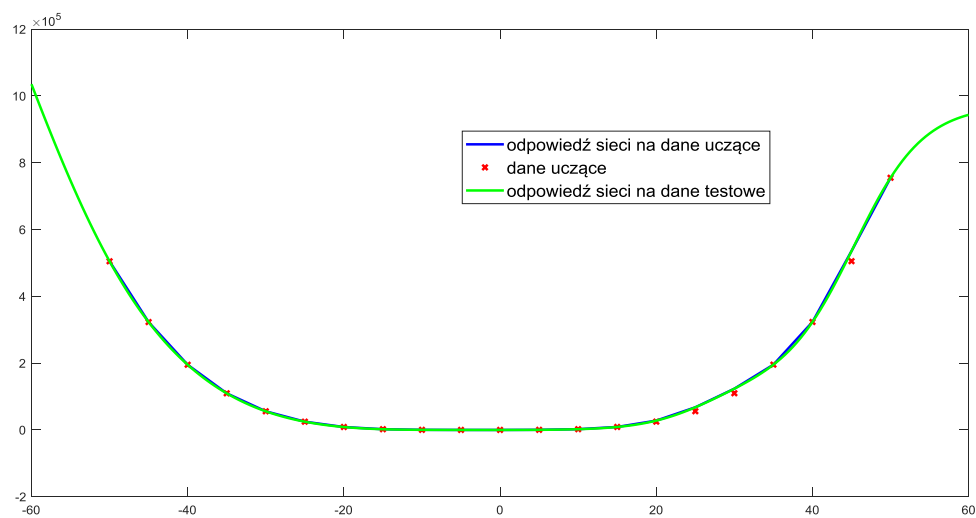


Rysunek 5 – Wyniki modelowania relacji statycznej dla liczby neuronów równej 3.

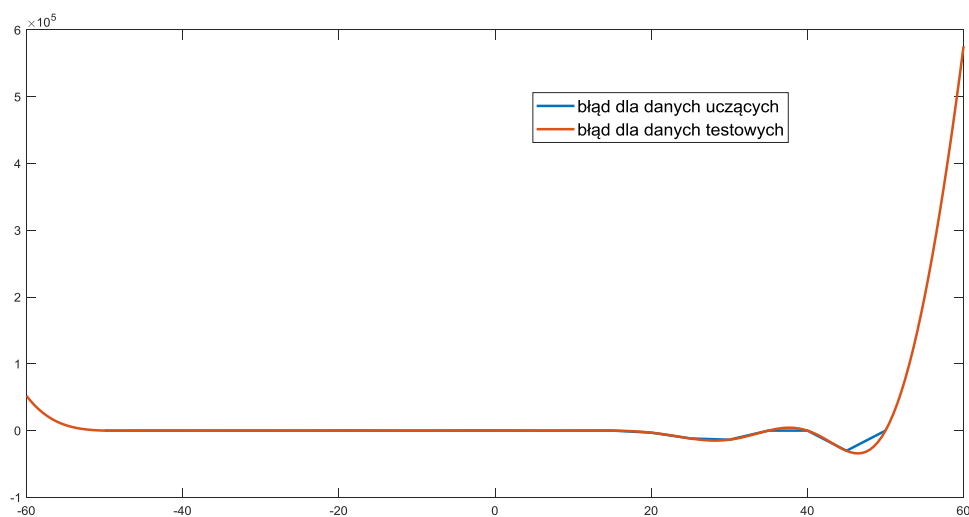


Rysunek 6 – Błąd modelowania relacji statycznej dla liczby neuronów równej 3.

W rezultacie otrzymano bardzo przyzwoite opisanie docelowej funkcji, co świadczy o dobrym zgeneralizowaniu problemu przez sieć (oczywiście tylko w zakresie danych uczących). Sprawdzone jeszcze jak sprawdzi się sieć złożona z 5 neuronów.




Rysunek 7 – Wyniki modelowania relacji statycznej dla liczby neuronów równej 5.




Rysunek 8– Błąd modelowania relacji statycznej dla liczby neuronów równej 5.

Otrzymane wyniki w większości są bardzo dobrze dopasowane. Dopiero dla wartości x większych od 40 pojawiają się znaczne odstępstwa.


Następnie przeprowadzono modelowania dla danych zaszumionych, z wykorzystaniem sieci neuronowych zbudowanych kolejno z 3 i 6 neuronów.



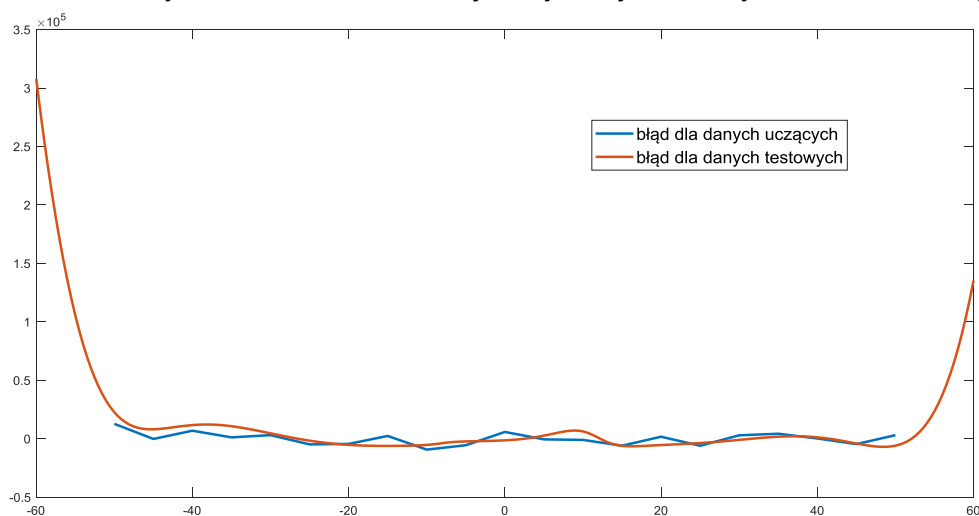
Rysunek 9 – Wyniki modelowania relacji statycznej dla liczby neuronów równej 3.



Rysunek 10 – Błąd modelowania relacji statycznej dla liczby neuronów równej 3.



Rysunek 11 – Wyniki modelowania relacji statycznej dla liczby neuronów równej 6.



Rysunek 12 – Błąd modelowania relacji statycznej dla liczby neuronów równej 6.

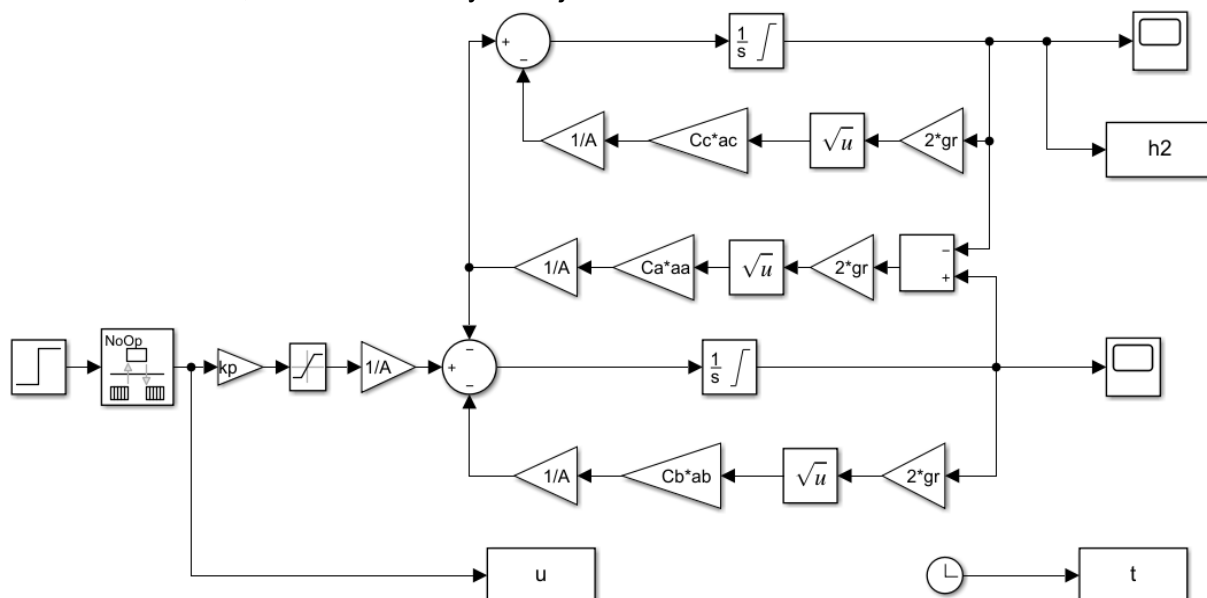
Wnioski:

Jeśli dane są bardzo mocno zakłócone, to otrzymane wyniki będą bezużyteczne. Przy stosunkowo małych szumach można otrzymać model, który będzie w pewnym stopniu poprawny dla danych uczących. Generalnie szumy powodują, że uczenie sieci jest mniej efektywne i ciężiej otrzymać model funkcji, który będzie jej odpowiadał. Ale można otrzymać też bardzo zadowalające wyniki, porównywalne z przypadkiem czystych danych.

Może się zdarzyć, że nawet przy danych niezaszumionych sieć neuronowa da wyniki zupełnie różne od funkcji. Wynika to z tego, że wagi początkowe sieci neuronowej są wybierane losowo, a algorytm minimalizacyjny zatrzymuje się w różnych minimach lokalnych.

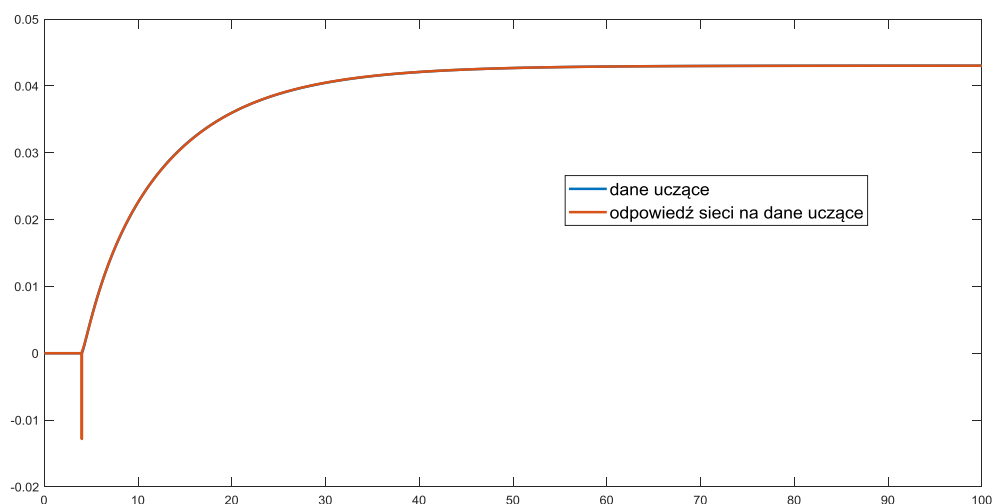
3 Modelowanie sztuczną siecią neuronową układu złożonego z dwóch zbiorników.

Na podstawie opisu układu z instrukcji do ćwiczenia stworzono model w Simulinku, w celu pobrania danych do uczenia sieci neuronowej. Zastosowano następujące ograniczenia sygnałów: wysokość cieczy w zbiornikach nie może być ujemna, przepływ pompy może zawierać się w zakresie od 0 do Q_{max} . W celach symulacji sygnału wejściowego wykorzystano skok o wartości 10, w 4 sekundzie symulacji.

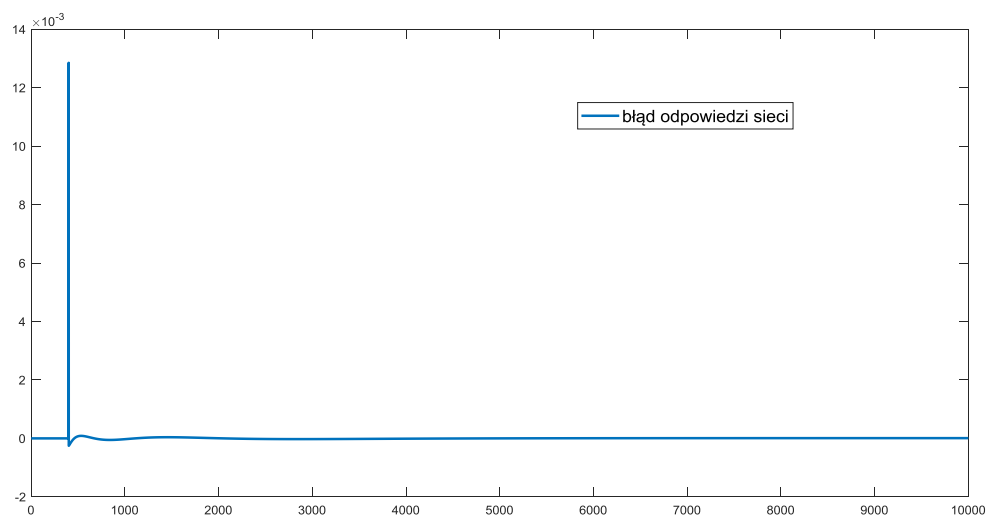


Rysunek 13 – Model dwóch zbiorników.

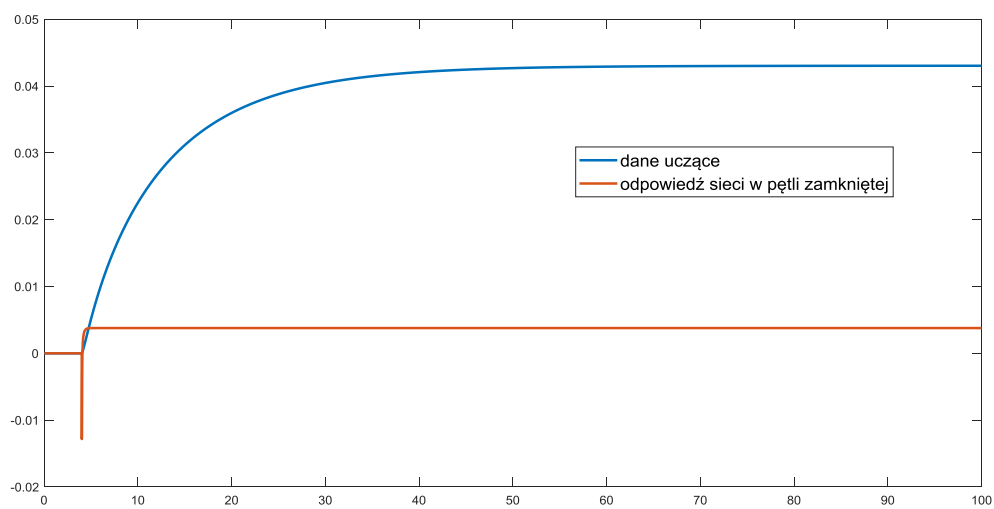
Otrzymane dane wykorzystano jako dane uczące sieci neuronowej. W pierwszej kolejności przeprowadzono nauczanie sieci złożonej z 5 neuronów, algorytmem Levenberg-Marquardt'a. Przeprowadzono też nauczanie sieci z sprzężeniem.




Rysunek 14 – Wyniki modelowania układu zbiorników dla liczby neuronów równej 5.



Rysunek 15 – Błąd modelowania układu zbiorników dla liczby neuronów równej 5.




Rysunek 16 – Wyniki modelowania układu zbiorników dla liczby neuronów równej 5 (sieć z sprzężeniem).




Rysunek 17 – Błąd modelowania sieci układu zbiorników dla liczby neuronów równej 5 (sieć z sprzężeniem).

Można zauważyć, że momencie pojawienia się skoku sygnału wejściowego sieć ma największy błąd. Przyczyną tego może być nagła zmiana wartości danych uczących (co jest zjawiskiem nieliniowym i prawdopodobnie algorytm sieci nie pozwala na dobre odwzorowanie takich danych). Sieć z sprzężeniem w tym przypadku daje wyniki zupełnie nie odpowiadające danym uczącym. Dlatego, nie będzie ona dalej przedstawiana.

W następnej kolejności zwiększono liczbę neuronów do 10.




Rysunek 18 – Wyniki modelowania układu zbiorników dla liczby neuronów równej 10.




Rysunek 19 – Błąd modelowania układu zbiorników dla liczby neuronów równej 10.

Jak widać w tym przypadku udało uzyskać się bardzo mały błąd, co świadczy o dobrym nauczaniu sieci.

Następnie zastosowano algorytm uczenia sieci: „Scaled Conjugate Gradient”, z liczbą neuronów 5.




Rysunek 20 – Wyniki modelowania układu zbiorników dla liczby neuronów równej 5.




Rysunek 21 – Błąd modelowania układu zbiorników dla liczby neuronów równej 5.

Mimo że błąd odpowiedzi sieci jest niewielki, to są widoczne różnice między danymi uczącymi, a odpowiedzią sieci na dane uczące. W porównaniu do poprzedniego algorytmu, w tym przypadku błędy wydają się mieć charakter mniej dynamicznych.

Następnie przeprowadzono uczenie sieci z zaszumionymi danymi o wartości $\pm 0,0005$. Liczba neuronów: 5, algorytm Levenberg-Marquardt'a. Przy obliczaniu błędu odpowiedzi sieci odniesiono się do danych idealnych.




Rysunek 22 – Wyniki modelowania układu zbiorników dla liczby neuronów równej 5 (szumy).




Rysunek 23 – Błąd modelowania układu zbiorników dla liczby neuronów równej 5 (szumy).

Następnie zwiększono liczbę neuronów do 20.



Rysunek 24 – Wyniki modelowania układu zbiorników dla liczby neuronów równej 20 (szumy).



Rysunek 25 – Błąd modelowania układu zbiorników dla liczby neuronów równej 20 (szumy).

Można stwierdzić, że gdy dane uczące są zaszumione, to odpowiedź sieci też jest zaszumiona. Wskazuje to, że sieć uczy się szumów.

W niektórych przypadkach uczenia sieci, odpowiedź sieci też miała peak jak na rysunku 14. Prawdopodobnie zależy to od tego, w którym momencie sieć kończy naukę.

Wnioski:

- Sieć z sprzężeniem nie daje dobrych rezultatów w przypadku takiego układu. Możliwe, że wynika to liczby zmiennych stanu i ilości równań układu (w tym przypadku były to 2 równania, a zmienne stanu to dwie wysokości cieczy w zbiorniku i ich pochodne).